UNIVERSIDAD TECNOLÓGICA DE TULA – TEPEJI

Ingeniería en Desarrollo y Gestión de Software

Grupo: 9 IDGS - G2

Asignatura: Extracción de Conocimiento en Bases de Datos

Recursamiento 2026

UNIDAD I

Planeación del Proyecto de Análisis de Datos

Proyecto: Estimación de edad y análisis morfológico de abulones

Alumno: Jorge Alberto Rodríguez Enríquez

Docente: Ing. José Luis Herrera Gallardo, MTI

Tula de Allende, Hidalgo, 2 de octubre de 2026

Índice

1. Descripción del proyecto 3

2. Planteamiento del problema 3

3. Pregunta principal de análisis 3

4. Objetivo general 4

5. Objetivos específicos 4

6. Alcance y limitaciones 4

6.1 Alcance (qué se analizará) 4

6.2 Limitaciones (qué queda fuera) 4

7. Descripción del conjunto de datos 5

7.1 Primera exploración 5

7.2 Posibles variables objetivo 6

8. Análisis comparativo: IA, Machine Learning, Data Mining y Big Data 6

8.1 Inteligencia Artificial (IA) 6

8.2 Machine Learning (ML) 6

8.3 Data Mining (Minería de datos) 7

8.4 Big Data 7

8.5 Cuadro comparativo resumido 7

9. Herramientas propuestas 8

10. Metodología de análisis de datos: CRISP-DM 8

11. Aplicación de la metodología al proyecto 9

12. Definición preliminar del análisis supervisado y no supervisado 9

12.1 Regresión 9

12.2 Clasificación 10

12.3 Análisis no supervisado 10

13. Resultados esperados 10

14. Cronograma preliminar 10

15. Referencias 11

1. Descripción del proyecto

El abulón es un molusco marino de una sola concha, parecido a un caracol de mar, que vive adherido a las rocas en zonas costeras. Es un marisco muy valorado y de alto precio comercial, por lo que se captura en el medio natural y también se cultiva en granjas de acuicultura. En distintos países su pesca está regulada, por ejemplo mediante tallas mínimas de captura, con el fin de que los ejemplares alcancen la edad suficiente para reproducirse antes de ser extraídos.

Conocer la edad de un abulón es importante para decidir cuándo cosecharlo, vigilar el crecimiento de un cultivo y estudiar la salud de sus poblaciones. Sin embargo, el método tradicional para determinarla consiste en cortar la concha, teñirla y contar sus anillos de crecimiento con un microscopio, lo cual es lento y requiere trabajo de laboratorio.

Este proyecto integrador utiliza el conjunto de datos *Abalone* del UCI Machine Learning Repository, que contiene medidas físicas de 4,177 abulones. A lo largo de las cinco unidades de la asignatura se planeará el análisis, se prepararán los datos, se construirán modelos para predecir la edad (análisis supervisado), se buscarán grupos de ejemplares con características parecidas (análisis no supervisado) y finalmente se presentarán los resultados en un dashboard.

2. Planteamiento del problema

Situación a analizar. Actualmente la edad de un abulón se determina contando los anillos de su concha bajo el microscopio, después de cortarla y teñirla. Este procedimiento es exacto, pero es lento, cansado, requiere equipo de laboratorio y personal capacitado, e implica sacrificar al ejemplar. Por ello no es práctico cuando se necesita conocer la edad de muchos abulones en poco tiempo. Es parecido a lo que ocurre con las personas: la forma más exacta de conocer la edad sería revisar sus huesos con radiografías, pero sería mucho más práctico estimarla con solo medir y pesar a la persona.

Relevancia. Granjas de acuicultura, pescadores, biólogos y autoridades pesqueras necesitan estimar la edad de los abulones para tomar decisiones de cosecha, regulación y conservación. Un método rápido y basado en medidas sencillas reduciría tiempos y costos.

Necesidad de información. Se necesita saber si las medidas físicas que se pueden obtener fácilmente (sexo, largo, diámetro, altura y pesos) contienen suficiente información para estimar la edad del abulón, cuáles de ellas son las más relacionadas con la edad y si existen perfiles o etapas de crecimiento que puedan identificarse a partir de esas medidas.

3. Pregunta principal de análisis

¿En qué medida las características físicas del abulón (sexo, dimensiones y pesos) permiten estimar su edad y reconocer perfiles o etapas de crecimiento?

Esta pregunta puede responderse con los datos disponibles, ya que el dataset incluye tanto las medidas físicas como el número de anillos (Rings), que representa la edad. Además,

conecta las tres partes del proyecto: regresión (estimar la edad), clasificación (etapa de crecimiento) y agrupamiento (perfiles).

4. Objetivo general

Desarrollar un proceso de análisis de datos, siguiendo la metodología CRISP-DM, que permita estimar la edad de los abulones y clasificarlos por etapa de crecimiento a partir de sus características físicas, así como identificar perfiles morfológicos, con el fin de generar conocimiento útil para la toma de decisiones en la acuicultura y el manejo pesquero.

5. Objetivos específicos

- **OE1.** Elaborar el diccionario de datos y un análisis exploratorio del dataset Abalone, identificando distribuciones, correlaciones y problemas de calidad (valores atípicos o imposibles), a más tardar el 9 de octubre de 2026.
- **OE2.** Preparar los datos mediante un proceso ETL en Python y diseñar un Data Mart en SQL Server, guardando los datos procesados en *data/processed* sin modificar los originales, a más tardar el 16 de octubre de 2026.
- **OE3.** Construir y comparar al menos dos modelos de regresión para predecir el número de anillos (Rings), evaluándolos con las métricas MAE, RMSE y R^2, a más tardar el 30 de octubre de 2026.
- **OE4.** Construir y comparar al menos dos modelos de clasificación para asignar a cada abulón un grupo de edad (Joven, Adulto, Maduro), evaluándolos con exactitud, precisión, recall, F1 y matriz de confusión, a más tardar el 30 de octubre de 2026.
- **OE5.** Aplicar al menos un algoritmo de agrupamiento (K-Means) y una técnica de reducción de dimensionalidad (PCA) para identificar perfiles morfológicos, a más tardar el 13 de noviembre de 2026.
- **OE6.** Presentar los hallazgos en un dashboard de Power BI con storytelling, conclusiones y recomendaciones, a más tardar el 20 de noviembre de 2026.

6. Alcance y limitaciones

6.1 Alcance (qué se analizará)

- Se trabajará únicamente con el dataset Abalone de UCI: 4,177 registros y 9 variables.
- Se realizará exploración, limpieza, transformación (ETL) y diseño de un Data Mart.
- Se construirán modelos de regresión y clasificación para estimar la edad, y modelos de agrupamiento y PCA para identificar perfiles.
- Los resultados se presentarán en un dashboard de Power BI y en informes por unidad.

6.2 Limitaciones (qué queda fuera)

- No se incluyen factores ambientales que influyen en el crecimiento (temperatura del agua, alimentación, ubicación, época del año), porque no están en el dataset.

- Los datos provienen de un estudio en Tasmania, Australia (1994); los resultados podrían no generalizarse a otras especies o regiones.
- La edad se obtiene a partir de los anillos (Rings + 1.5 años), por lo que es una aproximación.
- Algunas variables de peso (carne y vísceras) solo pueden medirse abriendo al abulón, lo que limita su uso práctico sin dañar al ejemplar.
- Los valores continuos están escalados (divididos entre 200) y existen registros con altura igual a cero que deberán revisarse.
- No se desarrollará una aplicación en producción; el modelo se presentará como prototipo académico.

7. Descripción del conjunto de datos

Aspecto	Descripción
Nombre	Abalone
Procedencia	UCI Machine Learning Repository (https://archive.ics.uci.edu/dataset/1/abalone). Datos originales del estudio de Nash et al. (1994), Tasmania, Australia.
Licencia	Creative Commons Attribution 4.0 (CC BY 4.0)
Tamaño	4,177 registros y 9 columnas (8 variables predictoras + 1 variable objetivo)
Formato	Archivo de texto separado por comas (abalone.data), sin encabezados
Valores faltantes	Ninguno
Ubicación en el proyecto	data/raw/abalone.data (copia original sin modificar)

Variable	Tipo de dato	Unidad	Descripción
Sex	Categórica nominal	—	M (macho), F (hembra), I (infante)
Length	Numérica continua	mm	Medida más larga de la concha
Diameter	Numérica continua	mm	Medida perpendicular al largo
Height	Numérica continua	mm	Altura con la carne dentro
Whole_weight	Numérica continua	g	Peso del abulón completo
Shucked_weight	Numérica continua	g	Peso de la carne
Viscera_weight	Numérica continua	g	Peso de las vísceras
Shell_weight	Numérica continua	g	Peso de la concha seca
Rings	Numérica entera	anillos	Número de anillos; edad ≈ Rings + 1.5 años (objetivo)

7.1 Primera exploración

La revisión preliminar mostró lo siguiente: la distribución por sexo es equilibrada (1,528 machos, 1,307 hembras y 1,342 infantes); Rings va de 1 a 29 anillos, con una media de 9.93 y una mediana de 9; no hay registros duplicados ni valores faltantes; y se encontraron 2 registros con altura igual a cero, que son físicamente imposibles y deberán tratarse en la

Unidad II. La variable con mayor correlación con Rings es el peso de la concha (Shell_weight, r = 0.63), seguida del diámetro (0.58), el largo y la altura (0.56).

7.2 Posibles variables objetivo

- **Regresión:** Rings (número de anillos, que representa la edad).
- **Clasificación:** grupo de edad derivado de Rings (Joven, Adulto, Maduro); el criterio se documenta en la sección 12.
- **No supervisado:** no tiene variable objetivo; se usarán las siete medidas físicas para descubrir grupos.

8. Análisis comparativo: IA, Machine Learning, Data Mining y Big Data

Estos cuatro conceptos están relacionados, pero no son lo mismo. La **Inteligencia Artificial** es el campo más amplio; el **Machine Learning** es una rama de la IA que aprende a partir de datos; el **Data Mining** usa técnicas estadísticas y de Machine Learning para descubrir patrones útiles en los datos; y el **Big Data** se refiere a volúmenes de datos tan grandes y variados que requieren tecnologías especiales para almacenarlos y procesarlos.

8.1 Inteligencia Artificial (IA)

Características	Campo de la computación que busca crear sistemas capaces de realizar tareas que requieren inteligencia humana: razonar, aprender, percibir, comprender lenguaje y tomar decisiones. Incluye ML, sistemas expertos, visión por computadora y procesamiento de lenguaje natural.
Beneficios	Automatiza tareas repetitivas, procesa información más rápido que una persona, apoya la toma de decisiones y funciona de forma continua.
Restricciones	Necesita grandes cantidades de datos y poder de cómputo; muchos modelos son difíciles de explicar ("caja negra"); no tiene sentido común ni comprensión real del contexto.
Retos	Sesgos en los datos, privacidad, ética, regulación, explicabilidad de las decisiones e impacto en el empleo.
Casos de aplicación	Asistentes virtuales y chatbots, vehículos autónomos, diagnóstico médico por imágenes, traducción automática, sistemas de recomendación.
Lenguajes y herramientas	Python, R, Java, C++; TensorFlow, PyTorch, Keras, OpenAI API, Hugging Face.

8.2 Machine Learning (ML)

Características	Rama de la IA en la que los sistemas aprenden patrones a partir de datos sin ser programados con reglas explícitas. Se divide en aprendizaje supervisado (regresión y clasificación), no supervisado (agrupamiento y reducción de dimensionalidad) y por refuerzo.
Beneficios	Hace predicciones a partir de datos históricos, mejora con más datos, se adapta a problemas muy distintos y descubre relaciones difíciles de ver a simple vista.
Restricciones	Depende de la calidad y cantidad de los datos; puede sobreajustarse (memorizar en lugar de aprender); requiere elegir y ajustar algoritmos e hiperparámetros.

Retos	Preparación y limpieza de datos, selección de variables, evitar sobreajuste, interpretar modelos y mantenerlos actualizados.
Casos de aplicación	Detección de fraude bancario, predicción de demanda, filtros de spam, mantenimiento predictivo, estimación de la edad de abulones (este proyecto).
Lenguajes y herramientas	Python y R; scikit-learn, XGBoost, TensorFlow, PyTorch, Pandas, NumPy; Jupyter Notebook.

8.3 Data Mining (Minería de datos)

Características	Proceso de descubrir patrones, tendencias, relaciones y conocimiento útil en grandes conjuntos de datos. Forma parte del proceso KDD (Knowledge Discovery in Databases) y combina estadística, bases de datos y Machine Learning. Sus tareas son clasificación, regresión, agrupamiento, asociación y detección de anomalías.
Beneficios	Convierte datos en conocimiento para la toma de decisiones, identifica segmentos de clientes, encuentra relaciones ocultas y apoya la planeación estratégica.
Restricciones	Los patrones encontrados no siempre implican causalidad; requiere datos limpios e integrados; los resultados dependen de una buena interpretación del contexto.
Retos	Integrar datos de diferentes fuentes, manejar datos faltantes o erróneos, privacidad de la información y validar que los patrones sean realmente útiles.
Casos de aplicación	Análisis de canasta de mercado, segmentación de clientes, detección de fraudes, análisis de rendimiento académico, perfiles morfológicos en biología.
Lenguajes y herramientas	Python, R, SQL; Weka, RapidMiner, KNIME, Orange, SQL Server Analysis Services.

8.4 Big Data

Características	Conjuntos de datos tan grandes, rápidos o variados que no pueden procesarse con herramientas tradicionales. Se describe con las "V": Volumen, Velocidad, Variedad, Veracidad y Valor. Usa almacenamiento y procesamiento distribuido.
Beneficios	Permite analizar información masiva en tiempo casi real, combinar datos de muchas fuentes (redes sociales, sensores, transacciones) y descubrir tendencias a gran escala.
Restricciones	Requiere infraestructura costosa (clústeres, nube), personal especializado y procesos complejos de gestión; no todo problema necesita Big Data.
Retos	Seguridad y privacidad, calidad de los datos, almacenamiento, integración de datos no estructurados y escasez de especialistas.
Casos de aplicación	Análisis de redes sociales, ciudades inteligentes, sensores IoT, comercio electrónico a gran escala, monitoreo de tráfico y genómica.
Lenguajes y herramientas	Python, Scala, Java, SQL; Apache Hadoop, Apache Spark, Kafka, bases NoSQL (MongoDB, Cassandra), servicios en la nube (AWS, Azure, Google Cloud).

8.5 Cuadro comparativo resumido

Aspecto	IA	Machine Learning	Data Mining	Big Data
Enfoque	Simular inteligencia humana	Aprender de los datos para predecir	Descubrir patrones y conocimiento	Almacenar y procesar datos masivos

Aspecto	IA	Machine Learning	Data Mining	Big Data
Pregunta que responde	¿Cómo hago que una máquina actúe de forma inteligente?	¿Qué pasará?	¿Qué patrones existen?	¿Cómo manejo tantos datos?
Relación	Campo general	Subcampo de la IA	Usa técnicas de ML y estadística	Provee los datos e infraestructura
Herramienta típica	TensorFlow, PyTorch	scikit-learn	Weka, KNIME, Python	Hadoop, Spark
Uso en este proyecto	Marco general	Modelos de regresión, clasificación y clustering	Exploración y descubrimiento de perfiles	No aplica: 4,177 registros es un volumen pequeño

Para este proyecto, el enfoque principal es **Machine Learning** y **Data Mining**. El dataset es pequeño, por lo que no se requieren tecnologías de Big Data; sin embargo, la metodología y las herramientas seleccionadas podrían escalar si en el futuro se integraran más datos.

9. Herramientas propuestas

Herramienta	Uso en el proyecto	Justificación
Python 3	Lenguaje principal para todo el análisis	Gratuito, el más usado en ciencia de datos, con gran comunidad y bibliotecas especializadas.
Jupyter Notebook / VS Code	Entorno de desarrollo	Jupyter permite combinar código, resultados y explicaciones; VS Code facilita organizar scripts y usar Git.
Pandas	Carga, exploración, limpieza y transformación (ETL)	Manejo eficiente de datos tabulares como el archivo abalone.data.
NumPy	Cálculos numéricos	Base matemática de Pandas y scikit-learn; operaciones rápidas con arreglos.
scikit-learn	Regresión, clasificación, K-Means, PCA y métricas	Biblioteca estándar de ML, con interfaz sencilla y documentación amplia.
Matplotlib / Seaborn	Gráficas exploratorias	Histogramas, diagramas de caja, mapas de correlación y gráficas de clusters.
SQL Server	Data Warehouse / Data Mart	Gestor robusto, solicitado por la asignatura y compatible con Power BI.
Power BI	Dashboard final	Visualización interactiva y storytelling; conexión directa con SQL Server.
Git y GitHub	Control de versiones y entregas	Registro de avances progresivos mediante commits y respaldo en la nube.

10. Metodología de análisis de datos: CRISP-DM

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) es una metodología creada a finales de los años noventa por un consorcio de empresas (entre ellas SPSS, NCR y DaimlerChrysler) para guiar proyectos de minería de datos de forma ordenada. Es independiente de la industria y de la herramienta, y es una de las metodologías más utilizadas en ciencia de datos. Se compone de seis fases **iterativas**: es posible regresar a una fase

anterior cuando se descubre algo nuevo.

Fase	Descripción
1. Comprensión del negocio	Entender el problema, los objetivos y los criterios de éxito desde el punto de vista del usuario; convertirlos en un problema de análisis de datos.
2. Comprensión de los datos	Recolectar los datos, describirlos, explorarlos y verificar su calidad.
3. Preparación de los datos	Seleccionar, limpiar, transformar, integrar y dar formato a los datos para el modelado. Suele ser la fase que más tiempo consume.
4. Modelado	Seleccionar técnicas, construir los modelos y ajustar sus parámetros.
5. Evaluación	Medir el desempeño de los modelos y verificar que realmente responden a los objetivos del negocio.
6. Despliegue	Poner los resultados a disposición de los usuarios: reportes, dashboards o integración en sistemas.

Se eligió CRISP-DM frente a otras metodologías como KDD o SEMMA porque inicia con la comprensión del problema real (no solo de los datos), es flexible e iterativa y sus fases coinciden de forma natural con las cinco unidades de la asignatura.

11. Aplicación de la metodología al proyecto

Fase CRISP-DM	Actividades en el proyecto Abalone	Unidad / fecha
1. Comprensión del negocio	Definir el problema de estimar la edad sin cortar la concha, la pregunta principal, los objetivos y el alcance.	Unidad I · 2 oct
2. Comprensión de los datos	Diccionario de datos; estadísticas descriptivas; histogramas y correlaciones; detección de valores atípicos y alturas iguales a cero.	Revisión U-II · 9 oct
3. Preparación de los datos	Asignar nombres a columnas, tratar registros inválidos, codificar Sex (one-hot), escalar variables, crear la variable Grupo_Edad, guardar en data/processed y cargar al Data Mart en SQL Server.	Unidad II · 16 oct
4. Modelado	Regresión: lineal, árbol de decisión y Random Forest. Clasificación: regresión logística, KNN y Random Forest. No supervisado: K-Means y PCA.	Unidades III y IV · 23 oct a 6 nov
5. Evaluación	Comparar modelos con MAE, RMSE, R^2, exactitud, F1 y matriz de confusión; optimizar con validación cruzada; evaluar clusters con método del codo y coeficiente de silueta.	Unidades III y IV · 30 oct y 13 nov
6. Despliegue	Dashboard en Power BI, storytelling, repositorio final, informe y defensa.	Unidad V · 17 y 20 nov

12. Definición preliminar del análisis supervisado y no supervisado

12.1 Regresión

Qué se predecirá: el número de anillos (**Rings**), una variable numérica entera que representa la edad (edad ≈ Rings + 1.5 años). **Variables predictoras:** Sex (codificada), Length, Diameter, Height, Whole_weight, Shucked_weight, Viscera_weight y Shell_weight. **Justificación:** Rings es un valor numérico, por lo que se trata de un problema de regresión; además, todas las medidas físicas muestran una correlación positiva moderada con Rings (de

0.42 a 0.63), lo que indica que contienen información útil para estimarla. **Métricas:** MAE, RMSE y R^2.

12.2 Clasificación

Qué se clasificará: el grupo de edad del abulón, una nueva variable categórica (**Grupo_Edad**) creada a partir de Rings. **Criterio de corte:** se usaron los cuartiles de Rings (Q1 = 8, mediana = 9, Q3 = 11) para formar tres clases de tamaño similar, lo que evita un desbalance de clases:

Clase	Criterio	Edad aproximada	Registros	Porcentaje
Joven	Rings ≤ 8	≤ 9.5 años	1,407	33.7%
Adulto	9 ≤ Rings ≤ 10	10.5 a 11.5 años	1,323	31.7%
Maduro	Rings ≥ 11	≥ 12.5 años	1,447	34.6%

Variables predictoras: las mismas ocho de la regresión; Rings no se usará como predictor porque de ella se deriva la clase. **Métricas:** exactitud (accuracy), precisión, recall, F1 y matriz de confusión. Los cortes podrán ajustarse si el docente lo indica.

12.3 Análisis no supervisado

Se aplicará **K-Means** sobre las siete medidas físicas escaladas, sin usar Rings, para descubrir grupos naturales de abulones con formas y pesos parecidos; después se comparará cada grupo con el sexo y la edad. Además, como las medidas físicas están muy correlacionadas entre sí (un abulón más largo también es más ancho y más pesado), se aplicará **PCA** para reducirlas a pocos componentes que conserven la mayor parte de la información y permitan visualizar los grupos en dos dimensiones.

13. Resultados esperados

- Un dataset limpio y documentado, con diccionario de datos y un Data Mart en SQL Server.
- Identificación de las medidas físicas más relacionadas con la edad; se espera que el peso de la concha y el diámetro sean de las más importantes.
- Un modelo de regresión capaz de estimar el número de anillos con un error medio de aproximadamente 1.5 a 2 anillos.
- Un modelo de clasificación que asigne el grupo de edad con una exactitud superior a la de una asignación al azar (33%).
- Perfiles morfológicos de abulones obtenidos con K-Means y su visualización mediante PCA, incluyendo la diferencia entre infantes y adultos.
- Un dashboard en Power BI con conclusiones y recomendaciones para granjas de acuicultura y manejo pesquero.

14. Cronograma preliminar

Fecha	Etapa del calendario oficial	Actividades del proyecto	Fase CRISP-DM
28 sep	Actividad 0	Registro, descarga del dataset y creación del repositorio	Comprensión de los datos (inicial)
2 oct	Unidad I (20%)	Documento de planeación, README actualizado	Comprensión del negocio
9 oct	Revisión Unidad II	Diccionario de datos, EDA, limpieza inicial, propuesta de Data Mart	Comprensión de los datos
16 oct	Unidad II (15%)	ETL en Python, datos procesados, esquema y scripts SQL	Preparación de los datos
23 oct	Revisión Unidad III	Modelos de regresión y clasificación funcionando	Modelado
30 oct	Unidad III (25%)	Métricas, optimización e informe	Modelado y evaluación
6 nov	Revisión Unidad IV	K-Means y PCA funcionando	Modelado
13 nov	Unidad IV (25%)	Evaluación, interpretación de perfiles e informe	Evaluación
17 nov	Revisión Unidad V	Dashboard y storytelling preliminar	Despliegue
20 nov	Unidad V (15%) y cierre	Dashboard final, repositorio, informe y defensa	Despliegue

15. Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine, 17*(3), 37–54.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95.

Mayer-Schönberger, V., & Cukier, K. (2013). *Big data: A revolution that will transform how we live, work, and think*. Houghton Mifflin Harcourt.

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61).

Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994). *Abalone* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C55C7W

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39).