UNIVERSIDAD TECNOLÓGICA DE TULA – TEPEJI

Ingeniería en Desarrollo y Gestión de Software

Grupo: 9 IDGS - G2

Asignatura: Extracción de Conocimiento en Bases de Datos

Recursamiento 2026 · Unidad II: Preparación de los datos

ACTIVIDAD DE EVALUACIÓN 1

Exploración, clasificación y diagnóstico del conjunto de datos

Proyecto: Estimación de edad y análisis morfológico de abulones

Dataset: Abalone (UCI Machine Learning Repository)

Alumno: Jorge Alberto Rodríguez Enríquez

Docente: Ing. José Luis Herrera Gallardo, MTI

Tula de Allende, Hidalgo, 9 de noviembre de 2026

Índice

1. Identificación del dataset 3
2. Carga y exploración inicial 3
2.1 Resultado de df.describe() 4
3. Diccionario de datos 4
3.1 Clasificación de las variables 4
4. Tipo y fuente de los datos 5
5. Diagnóstico de calidad 5
5.1 Valores faltantes 5
5.2 Registros duplicados 5
5.3 Valores incorrectos o inconsistentes 5
6. Análisis estadístico inicial 6
7. Detección inicial de valores atípicos 6
8. Visualización inicial 7
9. Preparación para análisis posteriores 9
10. Conclusión del diagnóstico 10
11. Evidencias en el repositorio 10
Referencias 10

1. Identificación del dataset

Aspecto	Descripción
Proyecto	Estimación de edad y análisis morfológico de abulones
Dataset	Abalone
Fuente	UCI Machine Learning Repository (https://archive.ics.uci.edu/dataset/1/abalone). Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994).
Formato	Archivo de texto plano *abalone.data* con valores separados por comas (CSV), sin fila de encabezados
Registros y variables	4,177 registros y 9 variables (8 predictoras + 1 objetivo)
Ubicación en el proyecto	data/raw/abalone.data (copia original sin modificaciones)
Descripción general	Cada fila es un abulón medido en un estudio de Tasmania, Australia: sexo, tres medidas de tamaño, cuatro medidas de peso y el número de anillos de la concha (Rings), que representa la edad (edad ≈ Rings + 1.5 años).

Toda la exploración se realizó en el notebook **Rodriguez_Enriquez_Jorge_Alberto_U2_AE1_Exploracion.ipynb** (carpeta notebooks/) con Python, Pandas y Matplotlib. En esta actividad **no se eliminó ni modificó ningún dato**: al final del notebook se verifica con *df.equals()* que el DataFrame analizado es idéntico al archivo original.

2. Carga y exploración inicial

Como el archivo no trae encabezados, se cargó indicando *header=None* y asignando los nombres oficiales de las columnas:

```
df = pd.read_csv(RUTA_RAW, header=None, names=COLUMNAS)
```

Instrucción	Qué hace	Resultado e interpretación
df.head()	Muestra las primeras 5 filas	Sex contiene letras (M, F, I); las medidas son decimales pequeños (0.455) y Rings son enteros. Los valores son pequeños porque las medidas continuas fueron **divididas entre 200** (0.455 → 91 mm).
df.shape	Devuelve (filas, columnas)	**(4177, 9)**: coincide con la ficha oficial de UCI; el archivo se leyó completo.
df.columns	Lista los nombres de las columnas	Las 9 columnas quedaron con los nombres asignados. Sin *names*=, pandas habría usado la primera fila de datos como encabezado y se habría perdido un registro.
df.info()	Resume no nulos, tipos y memoria	Las 9 columnas tienen 4,177 valores no nulos (**sin faltantes**); 1 object, 7 float64 y 1 int64; menos de 0.5 MB.
df.dtypes	Tipo de dato por columna	Sex = object (categoría, habrá que codificarla); medidas = float64; Rings = int64. Los tipos son coherentes: no hay números guardados como texto.
df.describe()	Estadística descriptiva	Height tiene **mínimo 0** (imposible) y **máximo 1.13** (extremo); Rings va de 1 a 29 con media 9.93 y mediana 9; en los pesos la media es mayor que la mediana (sesgo a la derecha).

2.1 Resultado de df.describe()

Variable	count	mean	std	min	25%	50%	75%	max
Length	4177	0.524	0.12	0.075	0.45	0.545	0.615	0.815
Diameter	4177	0.408	0.099	0.055	0.35	0.425	0.48	0.65
Height	4177	0.14	0.042	0	0.115	0.14	0.165	1.13
Whole_weight	4177	0.829	0.49	0.002	0.442	0.8	1.153	2.826
Shucked_weight	4177	0.359	0.222	0.001	0.186	0.336	0.502	1.488
Viscera_weight	4177	0.181	0.11	0	0.094	0.171	0.253	0.76
Shell_weight	4177	0.239	0.139	0.002	0.13	0.234	0.329	1.005
Rings	4177	9.934	3.224	1	8	9	11	29

3. Diccionario de datos

Variable	Descripción	Tipo Python	Tipo de variable	Clasificación	Unidad	Posible utilidad
Sex	Sexo: M macho, F hembra, I infante	object	Cualitativa	Nominal	—	Predictora; comparar grupos
Length	Medida más larga de la concha	float64	Cuantitativa	Continua	mm (÷200)	Predictora; clustering
Diameter	Medida perpendicular al largo	float64	Cuantitativa	Continua	mm (÷200)	Predictora; clustering
Height	Altura con la carne dentro	float64	Cuantitativa	Continua	mm (÷200)	Predictora; requiere revisión
Whole_weight	Peso del abulón completo	float64	Cuantitativa	Continua	g (÷200)	Predictora; clustering
Shucked_weight	Peso de la carne	float64	Cuantitativa	Continua	g (÷200)	Predictora; valor comercial
Viscera_weight	Peso de las vísceras	float64	Cuantitativa	Continua	g (÷200)	Predictora
Shell_weight	Peso de la concha seca	float64	Cuantitativa	Continua	g (÷200)	Predictora más relacionada con la edad
Rings	Anillos de la concha; edad ≈ Rings + 1.5	int64	Cuantitativa	Discreta	anillos	Objetivo de regresión; base de Grupo_Edad

3.1 Clasificación de las variables

- **Cualitativa nominal (1):** Sex. Sus categorías no tienen un orden natural.
- **Cuantitativas continuas (7):** Length, Diameter, Height, Whole_weight, Shucked_weight, Viscera_weight y Shell_weight. Pueden tomar cualquier valor decimal dentro de un rango.
- **Cuantitativa discreta (1):** Rings. Es un conteo, por lo que solo toma valores enteros.
- No hay variables binarias, ordinales ni de fecha.

4. Tipo y fuente de los datos

Procedencia: estudio biológico del Departamento de Industria Primaria y Pesca de Tasmania (Nash et al., 1994), donado en 1995 al UCI Machine Learning Repository, que lo publica bajo licencia CC BY 4.0.

Tipo de datos: generados por personas. Investigadores midieron manualmente cada abulón con instrumentos de medición (vernier y báscula) y contaron sus anillos al microscopio después de cortar y teñir la concha. No son datos de transacciones (no registran compras ni operaciones), ni de la web o medios sociales, ni lecturas automáticas de máquinas o sensores, ni datos biométricos de personas.

Clasificación de la fuente: estructurada. Es una tabla con filas y columnas fijas, el mismo número de campos en cada registro y un tipo de dato definido por columna; puede cargarse directamente en pandas o en una base de datos relacional como SQL Server.

5. Diagnóstico de calidad

5.1 Valores faltantes

```
df.isnull().sum()
```

El resultado es **0 en las 9 variables (0%)**. La documentación de UCI indica que los ejemplos con valores faltantes se eliminaron en el estudio original. **Tratamiento propuesto:** no se requiere imputación; en el ETL se incluirá una validación automática para asegurar que siga sin faltantes tras las transformaciones.

5.2 Registros duplicados

```
df.duplicated().sum()
```

Resultado: **0 registros duplicados**. Si existieran, una causa posible sería capturar dos veces el mismo abulón o unir archivos con información repetida. **Tratamiento propuesto:** no aplica eliminar duplicados; como el dataset no tiene un identificador propio, se agregará la columna *ID_Abulon* para usarla como llave primaria en el Data Mart.

5.3 Valores incorrectos o inconsistentes

Se evaluaron reglas lógicas que todo abulón real debe cumplir:

Regla revisada	Registros	¿Es error?	Tratamiento propuesto
Sex distinto de M, F o I	0	—	Sin problema; se traducirá a Macho/Hembra/Infante
Medidas negativas	0	—	Sin problema
Altura igual a 0	2	Sí, imposible	Eliminar
Altura > 0.3 (0.515 y 1.13 = 103 y 226 mm)	2	Muy probable; el resto no supera 50 mm	Eliminar
Diámetro mayor que el largo	1	Sí; el largo es la medida mayor por definición	Eliminar o revisar
Peso de la carne > peso total	4	Sí, imposible	Eliminar
Peso de la concha > peso total	1	Sí, imposible	Eliminar

Regla revisada	Registros	¿Es error?	Tratamiento propuesto
Carne + vísceras + concha > peso total	155	No necesariamente: las partes se pesan por separado y el abulón pierde agua y sangre al abrirse	Conservar y documentar

Además: el archivo no trae encabezados y las medidas están escaladas (÷200). En total, menos del 0.3% de los registros presenta valores físicamente imposibles.

6. Análisis estadístico inicial

Se seleccionaron la edad (Rings), la variable más relacionada con ella (Shell_weight) y dos medidas de tamaño (Length y Height). Entre paréntesis, el valor real (× 200):

Variable	Media	Mediana	Mínimo	Máximo	Desv. estándar
Rings (anillos)	9.93	9	1	29	3.22
Shell_weight	0.239 (47.8 g)	0.234 (46.8 g)	0.002 (0.4 g)	1.005 (201 g)	0.139 (27.8 g)
Length	0.524 (104.8 mm)	0.545 (109 mm)	0.075 (15 mm)	0.815 (163 mm)	0.120 (24 mm)
Height	0.140 (28 mm)	0.140 (28 mm)	0 (0 mm)	1.130 (226 mm)	0.042 (8.4 mm)

- **Rings:** la edad típica es de 10.5 a 11.5 años; la desviación de 3.2 anillos indica variación moderada. El máximo de 29 anillos (≈ 30 años) es raro, pero posible.
- **Shell_weight:** media y mediana casi iguales (≈ 47 g); va desde crías de 0.4 g hasta ejemplares de 201 g.
- **Length:** la mediana (109 mm) es mayor que la media (105 mm), lo que indica una cola de ejemplares pequeños (infantes).
- **Height:** su mínimo de 0 y máximo de 226 mm confirman los errores de captura de la sección 5.3.

La amplia variación en tamaño y peso es positiva para el proyecto: indica que estas medidas pueden ayudar a distinguir abulones de distintas edades.

7. Detección inicial de valores atípicos

Se usaron diagramas de caja y la regla IQR: un valor es atípico si está fuera del intervalo [Q1 – 1.5·IQR, Q3 + 1.5·IQR], donde IQR = Q3 – Q1.

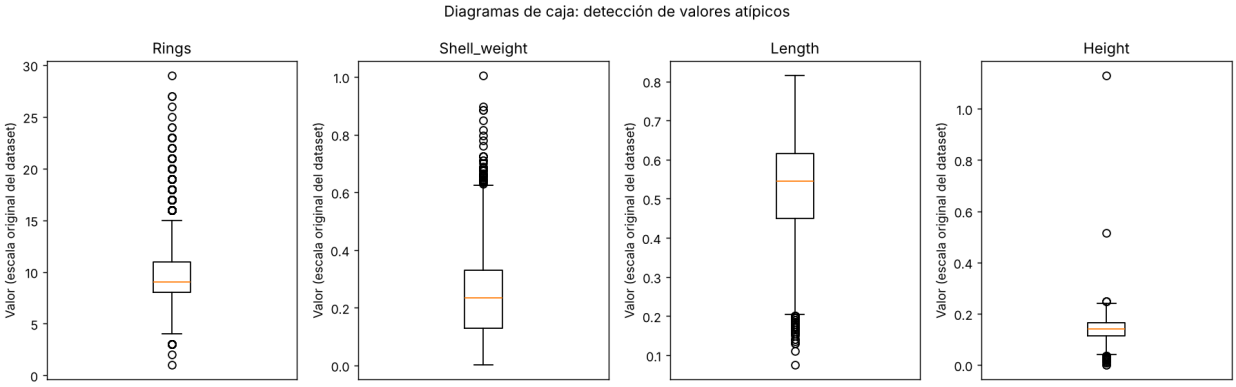


Figura 1. Diagramas de caja de Rings, Shell_weight, Length y Height (escala original del dataset).

Variable	Atípicos (IQR)	Comportamiento	¿Válido o error?	Tratamiento
Rings	278 (6.7%)	≤ 3 o ≥ 16 anillos	Válidos: ejemplares muy jóvenes o viejos	Conservar
Shell_weight	35 (0.8%)	Todos por arriba	Válidos: abulones grandes	Conservar
Length	49 (1.2%)	Todos por abajo	Válidos: crías pequeñas	Conservar
Height	29 (0.7%)	2 en cero y 2 muy aislados (0.515 y 1.13)	Los 4 son errores; el resto, válidos	Eliminar solo los 4 imposibles

Un valor atípico **no es lo mismo que un error**. Eliminar a los abulones muy viejos impediría que el modelo aprendiera a reconocerlos; por eso solo se eliminarán los valores físicamente imposibles, y **en esta actividad no se eliminó ninguno**.

8. Visualización inicial

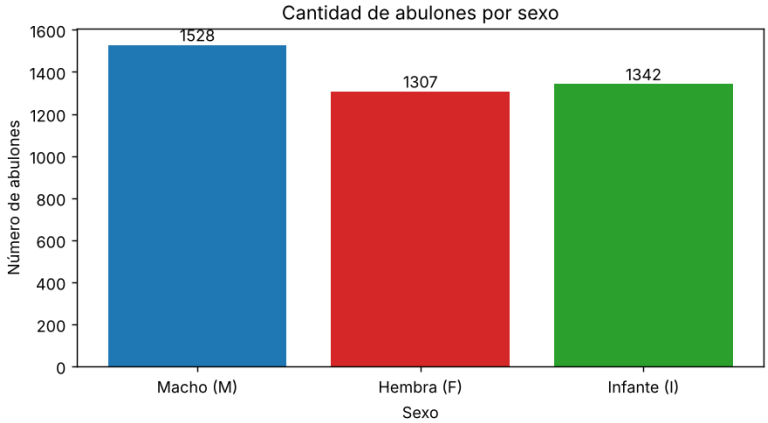


Figura 2. Cantidad de abulones por sexo.

Interpretación: las tres categorías están equilibradas (1,528 machos, 1,307 hembras y 1,342 infantes, alrededor de un tercio cada una), por lo que las comparaciones entre sexos son confiables.

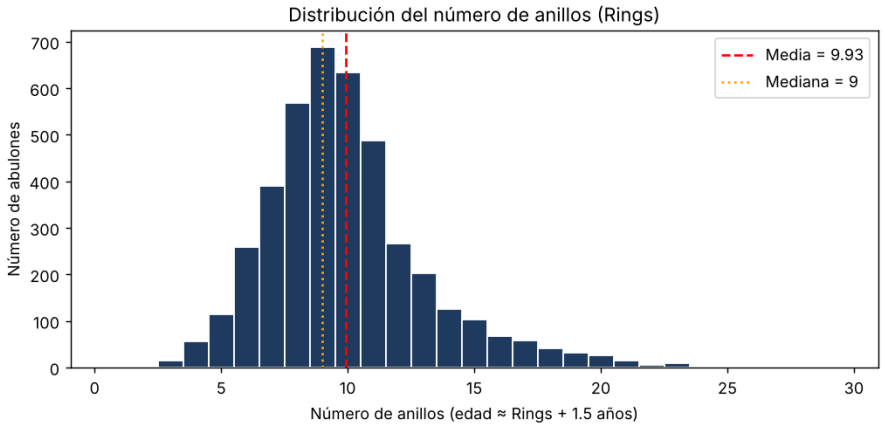


Figura 3. Distribución del número de anillos (Rings).

Interpretación: la mayoría de los abulones tiene entre 7 y 11 anillos y el valor más frecuente es 9. La cola hacia la derecha muestra pocos ejemplares muy viejos, lo que anticipa que los modelos predecirán mejor las edades intermedias.

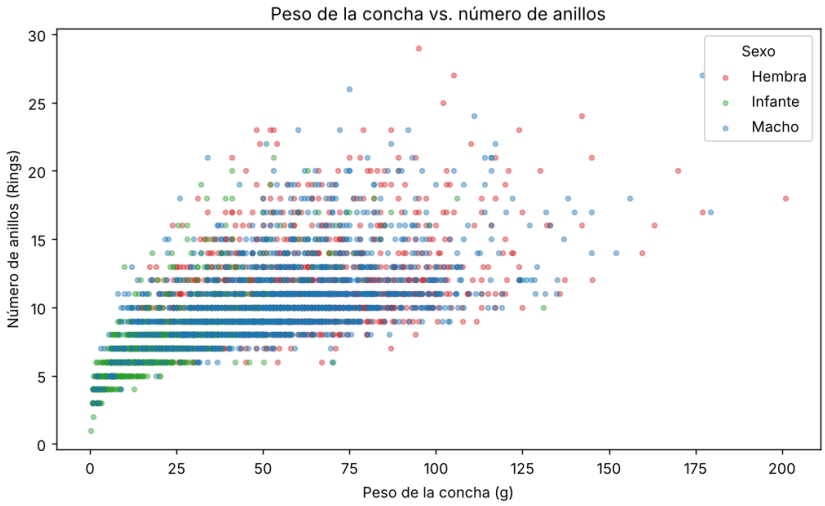


Figura 4. Peso de la concha (g) vs. número de anillos, por sexo.

Interpretación: existe una relación positiva (correlación 0.63, la más alta del dataset): a mayor peso de la concha, más anillos. Los infantes se concentran abajo a la izquierda. Entre los abulones pesados la edad varía mucho, porque al llegar a adultos casi dejan de crecer; estimar la edad de los ejemplares viejos será más difícil.

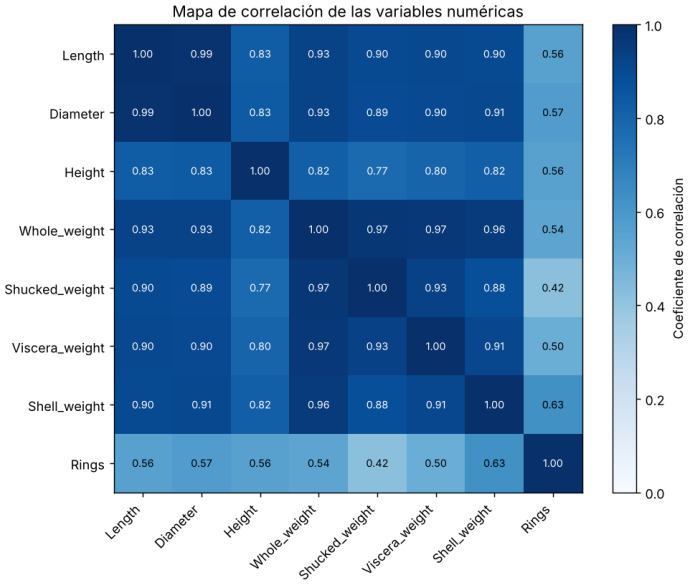


Figura 5. Mapa de correlación de las variables numéricas.

Interpretación: las medidas de tamaño y peso están muy correlacionadas entre sí (casi todas > 0.9) y moderadamente con Rings (0.42 a 0.63). Comparten mucha información, lo que justifica aplicar PCA en la Unidad IV.

9. Preparación para análisis posteriores

Análisis	Propuesta	Justificación (problema de la Unidad I)
Regresión	**Objetivo:** Rings. Predecir cuántos anillos tiene un abulón y, con ello, su edad (Rings + 1.5). **Entradas:** Sex (codificada), Length, Diameter, Height, Whole_weight, Shucked_weight, Viscera_weight y Shell_weight.	El problema es estimar la edad sin cortar la concha. Todas las medidas tienen correlación positiva con Rings (0.42 a 0.63).
Clasificación	**Objetivo:** nueva variable Grupo_Edad derivada de Rings, con 3 clases: **Joven** (≤ 8), **Adulto** (9 a 10) y **Maduro** (≥ 11), según los cuartiles de Rings. Entradas: las mismas 8 de la regresión.	A un productor le basta conocer la etapa de crecimiento (por ejemplo, si ya puede cosecharse). Las clases quedan balanceadas: 1,407 / 1,323 / 1,447. Rings no se usará como entrada para no dar la respuesta al modelo.
Agrupamiento	**Variables:** las 7 medidas físicas escaladas (Length, Diameter, Height, Whole_weight, Shucked_weight, Viscera_weight, Shell_weight), sin Rings ni Sex.	Busca descubrir perfiles morfológicos naturales y compararlos después con el sexo y la edad. Por su alta correlación se aplicará PCA junto con K-Means.

10. Conclusión del diagnóstico

#	Pregunta	Respuesta
1	¿Qué información contiene el dataset?	Medidas físicas (sexo, 3 dimensiones y 4 pesos) y el número de anillos (edad) de 4,177 abulones de Tasmania.
2	¿Cuál es su nivel general de calidad?	Alto: sin faltantes ni duplicados, tipos de dato correctos y menos del 0.3% de registros con valores imposibles.
3	¿Qué problemas fueron identificados?	Alturas en 0 (2), alturas extremas (2), un diámetro mayor que el largo (1) y pesos de partes mayores que el total (5); además, medidas escaladas y archivo sin encabezados.
4	¿Qué variables requieren tratamiento?	Height, Diameter/Length, Shucked_weight y Shell_weight (registros imposibles); Sex (codificación); medidas continuas (escalado y conversión a unidades reales).
5	¿Existen valores faltantes?	No, 0 en todas las variables.
6	¿Existen registros duplicados?	No, 0.
7	¿Existen valores atípicos?	Sí (por ejemplo, 278 en Rings), pero la mayoría son ejemplares reales y se conservarán; solo se eliminarán los imposibles.
8	¿Qué transformaciones serán necesarias?	Nombrar columnas, eliminar registros imposibles, convertir a unidades reales, crear Edad_anios y Grupo_Edad, codificar Sex, escalar, agregar ID y cargar en data/processed y en el Data Mart.
9	¿Los datos son adecuados para continuar?	Sí: tamaño suficiente, alta calidad y relación clara entre las medidas físicas y la edad.
10	¿Qué conocimiento podría obtenerse?	Qué medidas estiman mejor la edad sin sacrificar al animal, con qué precisión, a partir de qué tamaño un abulón es adulto y qué perfiles morfológicos existen; útil para acuicultura y manejo pesquero.

11. Evidencias en el repositorio

Repositorio: https://github.com/JaRe0528/REC_ECBD_2026_Rodriguez_Jorge

- notebooks/Rodriguez_Enriquez_Jorge_Alberto_U2_AE1_Exploracion.ipynb → notebook de exploración
- docs/Rodriguez_Enriquez_Jorge_Alberto_U2_AE1_Diagnostico.pdf → este informe
- docs/figuras/ae1_*.png → gráficas generadas por el notebook
- data/raw/abalone.data → dataset original sin modificaciones

Referencias

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61).

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95.

Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994). *Abalone* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C55C7W

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.